

Laporan Praktikum 1

***Preprocessing Data* dan PCA**

Laporan ini disusun untuk memenuhi penilaian Praktikum 1 mata kuliah Preprocessing Data dan PCA (AS4103)

Oleh :

Ulivia Embun Tresna Wardani

(10322015)



**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI ASTRONOMI
INSTITUT TEKNOLOGI BANDUNG
2024**

1. Dokumentasi Kode dan Sumber Data

Kode Python milik saya dalam Praktikum 1 ini dapat diakses pada colab berikut:

 [Punya Embun FIX] Praktikum 1_Data Preprocessing & PCA.ipynb


2. Matriks Korelasi

Pada tahap ini dibuat matriks korelasi antar fitur yang memiliki tipe data dalam bentuk angka. Matriks korelasi ini dibuat dengan tujuan membantu kita menganalisis korelasi antar fitur. Apabila nilai korelasi semakin mendekati +1 atau -1 artinya korelasi antar fitur semakin kuat. Sementara saat nilainya mendekati 0, artinya semakin tidak memiliki korelasi. Kemudian analisis tentang makna arahnya, yaitu positif atau negatif. Jika nilai korelasinya positif, artinya ketika nilai satu fitur naik, nilai fitur lainnya juga naik. Jika nilai korelasinya negatif, maka berlaku sebaliknya, yaitu saat satu fitur nilainya naik maka fitur lainnya akan menurun. Berikut adalah hasil matriks korelasi dari data yang diberikan.



Apabila diperhatikan pada hasil matriks korelasi tersebut, bagian segitiga atas kanan seperti mirro dari segitiga kiri bawah. Hal ini terjadi karena matriks korelasi bersifat simetris, yang artinya korelasi antara fitur A dan B sama dengan korelasi antara fitur B dan A.

Selain itu, terdapat cara lain untuk membuat visualisasi korelasi antar fitur, yaitu dengan membuat *pair plot* atau plot korelasi. Pair plot berwujud grid dari beberapa scatter plot, dimana setiapnya menunjukkan hubungan antara dua variabel atau fitur yang berbeda. Melalui scatter plot tersebut kita dapat mengidentifikasi pola, tren, atau korelasi antar fitur. Misainya apakah antar fitur memiliki hubungan linear, non-linear, atau bahkan tidak memiliki hubungan sama sekali. Berikut adalah pair plot dari data yang diberikan.



3. Deteksi Nilai Kosong (NaN), Data Duplikasi, dan Cara Penanganannya

Mendeteksi nilai kosong atau NaN dalam dataset sangat penting karena keberadaan nilai yang hilang dapat memengaruhi analisis, model prediktif, dan pengambilan keputusan. Jika tidak ditangani dengan baik, data yang hilang bisa

menyebabkan bias, mengurangi akurasi model, atau bahkan menghasilkan kesimpulan yang salah.


Pertama, kita cek tipe data dari setiap kolom apakah *integer*, *float*, atau *object*. Ternyata dapat dilihat bahwa dataset ini terdiri atas 14 kolom bertipe data numerik *float* dan 11 kolom bertipe data *object*. Detail informasi mengenai tipe data tiap kolom dapat dilihat pada output cell [8] di colab.

Selanjutnya baru kita cari tahu berapa banyak nilai kosong dan data yang berpotensi terduplikasi di setiap kolom. Perhitungan banyaknya nilai kosong (NaN) dan data duplikasi dilakukan pada cell [9] dan [10] pada colab. Hasilnya menunjukkan bahwa tidak ada data duplikasi pada dataset tersebut, tetapi ada banyak nilai NaN yang terdeteksi. Berikut adalah jumlah nilai kosong (NaN) pada tiap kolom.

No	Kolom	Jumlah NaN
1	age	9
2	bp	12
3	sg	47
4	al	46
5	su	49
6	rbc	152
7	pc	65
8	pcc	4
9	ba	4
10	bgr	44
11	bu	19
12	sc	17
13	sod	87
14	pot	88
15	hemo	52
16	pcv	71
17	wbcc	106
18	rbcc	131
19	htn	2
20	dm	2
21	cad	2
22	appet	1
23	pe	1
24	ane	1
25	class	0

Sebelum memutuskan bagaimana cara mengatasi data yang hilang ini, kita perlu mengidentifikasi terlebih dahulu data yang hilang masuk kategori kehilangan data yang mana. Apakah data hilang karena dipengaruhi oleh informasi lain yang diketahui, atau karena memang sengaja dihilangkan karena informasi terlalu *privacy*, atau mungkin memang hilang secara acak tanpa pola. Untuk mengetahui kategori ini,

kita dapat memanfaatkan *package missingno* dengan fungsi heatmap. Fungsi tersebut menghitung korelasi antara *nullity* dari kolom berbeda dalam DataFrame. Kemudian, divisualisasikan korelasinya sebagai heatmap. Berikut adalah heatmap korelasinya.



Warna yang semakin mendekati biru gelap menunjukkan korelasi positif yang kuat dalam kehilangan data, artinya apabila satu kolom memiliki nilai yang hilang, kolom lainnya juga cenderung memiliki nilai yang hilang. Sementara, warna yang semakin terang mendekati putih menunjukkan korelasi yang lemah, artinya data yang dari suatu kolom tidak memiliki hubungan kuat dengan hilangnya data pada kolom lainnya. Dalam kata lain kita bisa mengidentifikasi bahwa heatmap dengan korelasi lemah kemungkinan besar adalah *missing data* kategori MCAR, sedangkan yang memiliki korelasi kuat adalah *missing data* kategori MAR atau MNAR.

Kemudian, kita bisa mulai mengatasi data kosong (NaN) dari setiap kolom. Berikut adalah cara saya mengatasi nilai-nilai NaN tersebut beserta justifikasi pemilihan caranya.

No.	Kolom	Tipe Data	Metode Penanganan Nilai NaN	Justifikasi
1	age	Numerik	Imputasi dengan Median	Pertama, karena fitur umur memiliki distribusi tidak normal, yang cenderung ke arah kanan ataupun kiri. Jadi, tidak mungkin diisi menggunakan mean karena rentan terhadap outlier, sehingga paling cocok diisi dengan median.
2	bp	Numerik		

3	sg	Numerik	Imputasi dengan KNNImputer.	Fitur ini bertipe data ordinal dan KNNImputer dapat mempertimbangkan urutan nilai. Sehingga paling cocok menurut saya adalah imputasi dengan KNNImputer.
4	al	Numerik		
5	su	Numerik		
6	rbc	Objek	Diisi dengan “abnormal” jika class “ckd” dan diisi “normal” jika class “notckd”.	sesuai deskripsi pada modul bahwa jika rbc abnormal maka mengindikasikan ginjalnya rusak
7	pc	Objek	Diisi dengan “abnormal” jika class “ckd” dan diisi “normal” jika class “notckd”.	sesuai deskripsi pada modul bahwa jika pc abnormal maka mengindikasikan peradangan ginjal.
8	pcc	Objek	Dropping	Karena jumlah yang kosong hanya sedikit.
9	ba	Objek		
10	bgr	Numerik	Imputasi dengan Median	Pertama, karena fitur umur memiliki distribusi tidak normal, yang cenderung ke arah kanan ataupun kiri. Jadi, tidak mungkin diisi menggunakan mean karena rentan terhadap outlier, sehingga paling cocok diisi dengan median.
11	bu	Numerik		
12	sc	Numerik		
13	sod	Numerik		
14	pot	Numerik		
15	hemo	Numerik		
16	pcv	Numerik		
17	wbcc	Numerik		
18	rbcc	Numerik		
19	htn	Objek	Dropping	Karena jumlah yang kosong hanya sedikit.
20	dm	Objek		
21	cad	Objek		
22	appet	Objek		
23	pe	Objek		
24	ane	Objek		

4. Cek Format Penulisan Data Kategorikal dan Data Nominal

Hal ini dilakukan untuk memastikan data yang akan digunakan untuk membangun model dalam *Machine Learning* sudah benar-benar bersih dan tidak ada kesalahan kecil seperti typo atau adanya spasi tambahan. Pada data saya ternyata untuk dm dan class ternyata ditemukan adanya pertambahan spasi atau '\t'. Dan langsung dibersihkan.


5. Deteksi Outlier

Digunakan metode IQR (Inter Quartile Range) untuk mendefinisikan daerah mana yang termasuk bagian distribusi data inti. Jadi jika di luar itu, maka dianggap outlier.


6. Dissimilarity

Berikut visual hasil Dissimilarity yang paling baik, sehingga dapat dilihat dengan mudah seberapa jauh jarak data satu dengan lainnya. Jika nilainya rendah, artinya dia berjarak dekat, atau dapat dikatakan bahwa data tersebut mirip satu dengan lainnya. Begitu pula sebaliknya.


Numerik



Categorical




Combine



7. Analisis Korelasi dan Regresi


Dilakukan untuk mengeliminasi fitur-fitur yang sangat tidak berkorelasi secara umum pada dataset. Berikut adalah hasilnya.




8. PCA

Berdasarkan analisis yang dilakukan dengan algoritma di colab, didapatkan grafik kekuatan dari jumlah fitur untuk merepresentasikan isi data.

Numerik



Categorical/Object



Dapat dilihat bahwa hanya dengan menggunakan **10 fitur numerik** dan **8 fitur categorical** sudah cukup mengakomodasi informasi dari data sekitar **91%**. Dan menurut saya nilai 90% adalah batas terbaik untuk mengeliminasi fitur atau dimensi. Jika di bawah nilai tersebut, saya merasa bahwa ia belum cukup merepresentasikan data awal.